

Parcial 2022

$$1) a) \text{Rango Inter Quartil} = Q_3 - Q_1 = 141 - 97 = 44$$

$$LS = Q_3 + 1,5 \cdot RIQ = 207$$

$$LI = Q_1 - 1,5 \cdot RIQ = 31$$

Es atípico si está por fuera del rango $[31, 207]$

→ leve si está en el intervalo $[Q_1 - 3 \cdot RIQ, LI]$ o $[LS, Q_3 + 3 \cdot RIQ]$

→ extremo si es mayor a $Q_3 + 3 \cdot RIQ$ o menor a $Q_1 - 3 \cdot RIQ$

$$Q_1 - 3 \cdot RIQ = -35 \quad Q_3 + 3 \cdot RIQ = 273$$

Normalización lineal uniforme:
$$X'_1 = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$$

Normalización Estándar:
$$X'_2 = \frac{X - \text{media}(X)}{\text{desviación}(X)}$$

300

atípico extremo

$$X'_1 = 0,9$$

$$X'_2 = 4,16$$

30

atípico leve

$$X'_1 = 0,12$$

$$X'_2 = -2,33$$

250

atípico leve

$$X'_1 = 0,71$$

$$X'_2 = 2,95$$

200

No es atípico

$$X'_1 = 0,52$$

$$X'_2 = 1,75$$

NOTA

b) Los valores normalizados ^{linealmente} representan una transformación de los datos originales en una escala del 0 al 1, representando sus relaciones proporcionales, es muy sensible a valores atípicos (outliers) y si se recortan los extremos se obtienen valores negativos y/o mayores a 1 (valores inferiores al mínimo darán números negativos y mayores al máximo, mayores a 1)

c) Los valores normalizados con media y desvío representan una transformación de los datos para que tengan media 0 y desviación estándar 1. Se representa cuantas desviaciones estándar está un dato por encima o por debajo de la media, se suele usar si los datos tienen una distribución normal

d) la normalización con media y desvío se relaciona más con la detección de valores atípicos, ya que si un valor está entre 2 a 3 desviaciones estándar por encima o debajo de la media se consideran atípicos leves y si está a más de 3 es un atípico extremo. En cambio en la normalización lineal uniforme no tenemos forma de saber si un valor es atípico.

$$2) \quad y = \sum_{i=1}^n X_i w_i + \text{bias}$$

$$y = 10 \cdot 0,392 + 150 \cdot 0,001 + 2 \cdot (-2,441) + 0,4022$$

$$y = -0,4098$$

$$\text{función de activación umbral binaria: } \text{salida} = \begin{cases} 1 & \text{si } y \geq 0 \\ 0 & \text{si } y < 0 \end{cases}$$

$\Rightarrow \text{salida} = 0$, por lo que suponemos que no = 0 y si = 1, se puede ver que es no seleccionado

3) Perceptrón Combinador Lineal Neurona no lineal

Salida
neto $\sum X_i W_i + b$ $\sum X_i W_i + b$ $\sum X_i W_i + b$

Función de activación $[0,1]$ umbral binario $(-\infty, +\infty)$ función lineal $[0,1]$ $[-1,1]$ $(-\infty, +\infty)$ Sigmoide, tanh, Relu, etc

Salida $y = \begin{cases} 1 & \text{neto} \geq 0 \\ 0 & \text{neto} < 0 \end{cases}$ $y = \sum_{i=1}^n X_i W_i + W_0$ $y = \frac{1}{1 + e^{-x}}$ $y = \frac{e^x - e^{-x}}{e^x + e^{-x}}$
 $y = \max(0, x)$

tipo de problema que resuelve clasificación binaria en problemas linealmente separables regresión lineal clasificación binaria y regresión, incluso en problemas linealmente no separables

aprendizaje actualización vector Proyección $W_{nuevo} = W + \alpha (t - y) X$ t : valor esperado y : valor obtenido descenso de gradiente $W_{nuevo,i} = W_i + \alpha \frac{\partial (ECM)}{\partial W_i}$ $W_{nuevo,i} = W_i + \alpha \frac{\partial (C)}{\partial W_i}$ C : función de costo, puede ser ECM, Atrópico cruzado binario, etc

4/2)

59	X	X
0	34	34
0	X	X

$$\text{recall}_2 = 0,5 = \frac{TP}{TP+FN} = \frac{34}{34+FN} \Rightarrow FN = 34$$

(clase, predicción)

	(1,1)	(1,2)	(1,3)
matriz =	(2,1)	(2,2)	(2,3)
	(3,1)	(3,2)	(3,3)


$$\text{precisión} = \frac{\text{bien predichas}}{\text{bien predichas} + \text{intrusos}}$$

$$\text{recall} = \frac{\text{bien predichas}}{\text{bien predichas} + \text{los que fueron a parar a otro lado}}$$

$$\text{precisión clasificador} = \frac{\text{correctas}}{\text{totales}}$$

$$F1\text{-score} = \frac{\text{precision} \times \text{recall}}{\text{precision} + \text{recall}}$$

5)



$$\text{Sigmoide: } y_j = \frac{1}{1+e^{-x_j}}$$

$$\text{Softmax: } y = \frac{e^{\text{neto}_k}}{\sum_k e^{\text{neto}_k}}$$

2) Sigmoide: $y_1 = 0,18$

$y_2 = 0,98$

$y_3 = 0,99$

1) Softmax: $y_1 = 0,0005$

$y_2 = 0,11$

$y_3 = 0,88$

NOTA \Rightarrow el vino será de tipo 1

\Rightarrow el vino será de tipo 1

6/2) una función de costo sirve para ver que tan alejada está la predicción, debe devolver valores positivos, ser derivable y representar el error, donde tiende a 0, es por eso que sería ideal que todas las funciones de costo sean convexas. Si el costo es 0 significa que el modelo hizo una predicción perfecta, tiende a 0 a medida que la neurona aprende la salida deseada.

1) la entropía binaria cruzada resuelve en algunas situaciones el problema del desvanecimiento de gradiente con neuronas con función de activación sigmoide. Esto se debe a que el gradiente del ECM es $-(t_k - y_k) f'(net_k) x_j$ y el de la entropía cruzada Binaria es $-(t_k - y_k) x_j$, por lo que lo único que cambia es que en el ECM aparece la derivada de la función sigmoide y lo único que hace esto es multiplicarla por un factor de escala que va desde 0 a 0,25, entonces lo que termino haciendo es que el paso sea mucho más pequeño y tarde más el entrenamiento, es por eso que usamos la ECB, ya que produce gradientes más grandes y es más adecuada para clasificación binaria, ya que aprovecha la naturaleza probabilística de la sigmoide.

2) no podría usarse dado que el perceptrón no utiliza descenso de gradiente, actualiza el vector proyección. Además se suele usar en la función sigmoide y el perceptrón utiliza la función umbral.

7) al utilizar lotes de 150 estaríamos usando descenso de gradiente estocástico con mini lote, lo que hacemos es procesar 150 ejemplos, actualizar los pesos y así hasta haber completado todos los ejemplos, esto lo hacemos usando el.

NOTA

algoritmo de backpropagation. si no usamos lotes
puede ser que estemos usando descenso de gradiente completo
que es como el caso anterior pero como si tuvieramos lotes
del tamaño de la cantidad de ejemplos, o descenso de
gradiente estocástico que por cada ejemplo que entra se actualizan
los pesos

i) $3000 / 150 = 20$

20 iteraciones por época y 200 épocas
 \Rightarrow 4000 iteraciones

ii) los pesos se actualizarán 4000 veces

iii) con descenso de gradiente completo 200 veces
y con descenso de gradiente estocástico $3000 \cdot 200 = 600000$ veces

8) a)
$$\overset{\text{tamaño}}{\uparrow} (32 + 2 \cdot 0 - 4) / 2 + 1 = 15$$

$$\downarrow \quad \downarrow \quad \downarrow$$

padding kernel size stride

output-shape = $15 \times 15 \times 8$

b)
$$\underset{\substack{\downarrow \\ \text{filtros}}}{8} \cdot \underset{\substack{\downarrow \\ \text{kernel}}}{4} \cdot \underset{\substack{\downarrow \\ \text{kernel}}}{4} \cdot \underset{\substack{\downarrow \\ \text{estratos}}}{3} + \underset{\substack{\downarrow \\ \text{filtros} \times \text{el bias}}}{8} = 392$$